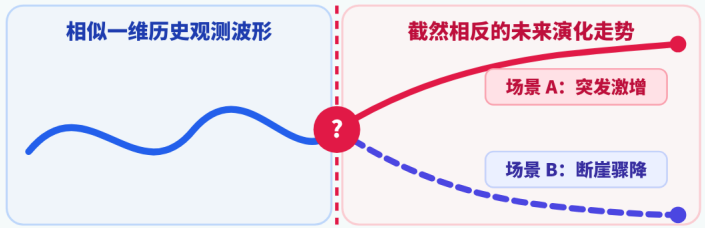
多模态生成式时间序列预测：痛点诊断与核心突破

从表征视角、跨模态信噪比与概率生成轨迹三个维度，对比传统单模态确定性回归的固有瓶颈与 Aurora 的针对性架构革新。

传统单模态确定性预测的三大固有瓶颈

瓶颈 01 一维单模态视角扁平，缺失跨周期与文本语境

表征视角受限

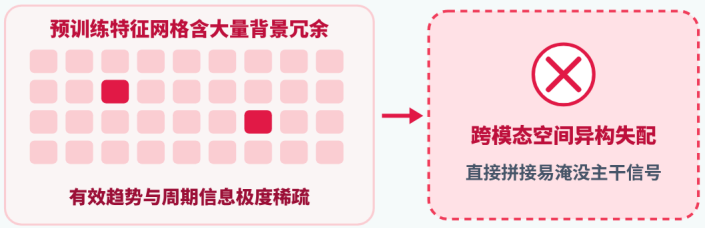


- 仅将历史观测视为扁平一维波形，多重潜伏周期混叠导致跨周期同相位关联难以显式对齐。
- 极端气象、节假日与宏观事件等关键外部驱动力存在于文本中，纯数值模型无法感知此类语境。

↓ 频域周期折叠 + 三路协同编码

瓶颈 02 预训练特征高度冗余，直接拼接干扰时序主干

信噪比失衡

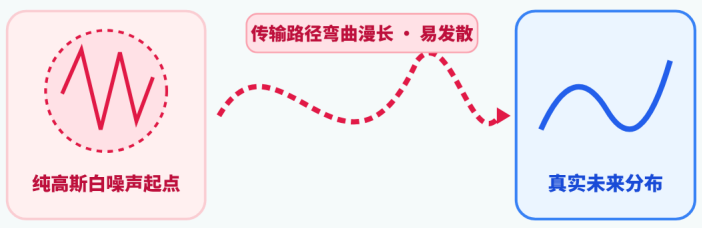


- 冻结的预训练视觉（ViT）与语言（BERT）模型输出数百个词元，包含大量无关语法与背景噪声。
- 异构模态特征空间与一维时间序列存在显著分布差异，简单拼接易导致跨模态注意力权重发散。

↓ 质心自适应蒸馏 + 双路相关性引导

瓶颈 03 点预测抹平多峰分布，纯噪声生成路径弯曲漫长

生成轨迹发散



- 传统均方误差（MSE）确定性回归仅能输出条件期望均值，无法刻画未来演化的多峰概率分布。
- 常规生成式模型从纯高斯白噪声 $\mathcal{N}(0, I)$ 出发，缺乏物理波形先验锚定，传输轨迹弯曲漫长。

↓ 先验基波原型检索 + 直线流匹配生成

Aurora 多模态生成式预测的核心突破

核心突破 01 内生一维与二维双视角及外生文本三路协同编码

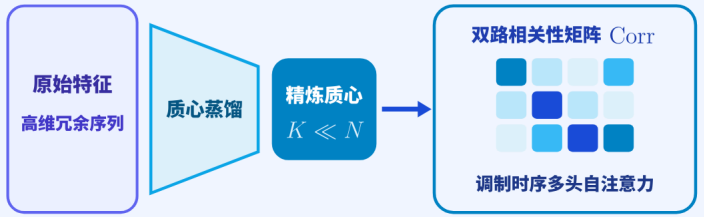
直达 P2–P4 ↗



- 无需外部配图：利用快速傅里叶变换自动识别主导周期 P，将一维序列折叠为二维周期图像。
- 构建外生领域文本、一维局部时序与二维内生周期图像三路并行编码架构，全面捕获多源先验。

核心突破 02 模态质心自适应蒸馏与双路引导多头自注意力

直达 P5–P6 ↗



- 设计可学习质心蒸馏器（Distiller），将冗长视觉与文本特征提纯为 K 个紧凑的核心领域质心。
- 通过双路引导器生成跨模态相关性矩阵 Corr，动态调制一维时序主干的多头自注意力权重。

核心突破 03 多尺度先验原型检索与原型引导直线流匹配生成

直达 P7 ↗



- 以精炼多模态特征检索可学习原型库，合成兼具周期与趋势形态的先验波形 $\tilde{\mathcal{P}}$ 作为生成起点。
- 在未来条件 X^{cond} 制导下预测最优传输直线速度场 v_θ，经少量几步欧拉积分生成预测分布 $\hat{Y}$。

Aurora 算法整体多路架构

编码器并行处理外生文本、一维历史序列与内生二维周期图像并融合为统一表征；解码器结合先验原型检索与未来条件解码，经流匹配生成预测分布。

Aurora Encoder · 三路并行编码与跨模态双路引导融合

- 上路: 外生文本流 (Sky)
- 中路: 1D 时序主干 (Royal Blue)
- 下路: 2D 周期图像流 (Indigo)
- 汇聚输出: X^fuse (Signal Teal)

上路支路 · 外生领域文本流 (Text Modality Stream)

领域文本 新闻 / 气象 / 领域描述

Tokenizer
文本分词与位置嵌入

TextEncoder (BERT)
冻结预训练参数 · 提取上下文

H^{text}

TextDistiller (质心蒸馏)
交叉注意力提纯核心语义质心

蒸馏文本质心
$\tilde{X}^{\text{text}} \in \mathbb{R}^{K \times D}$

中路主干 · 一维时间序列流 (1D Time Series Backbone Stream)

原始时间序列 (Time Series)
历史序列 $x_{1:T} \in \mathbb{R}^{T}$

FFT 提取主周期折叠成图

1D Tokenizer
RevIN 归一化 + 左补零
一维分块与动态重采样嵌入

时序块
X^{time}

TextGuider (时序-文本相关性引导)

模态引导多头自注意力 (MG-MSA)
注入双线性引导矩阵 Corr

Add & Norm
残差连接

FFN
前馈网络

×K 层
堆叠演化

VisionGuider (时序-视觉相关性引导)

引导后时序
$\tilde{X}^{\text{time}}$

下路支路 · 二维内生图像流 (2D Endogenous Image Stream · 由一维序列按主周期折叠生成)

二维内生周期图
$I \in \mathbb{R}^{H \times W \times 3}$

2D Tokenizer
二维网格分块 + 位置嵌入

VisionEncoder (ViT)
冻结预训练参数 · 提取周期纹理

H^{vis}

VisionDistiller (质心蒸馏)
交叉注意力提纯核心周期质心

蒸馏视觉质心
$\tilde{X}^{\text{image}} \in \mathbb{R}^{K \times D}$

三路跨模态对齐与融合 (Modality Fuser)

Modality Fuser
交叉注意力对齐
时序 + 视觉 + 文本残差相加

多模态融合表征
X^{fuse}
三路对齐编码输出

Aurora Decoder · 先验原型检索、未来条件解码与流匹配生成

- 解码上路: 原型库软检索 P̃ (Indigo)
- 解码下路: 因果 + RoPE 条件 X^cond (Royal Blue)
- 生成终端: 直线流匹配 ODE → Ŷ (Signal Teal)

解码上路 · 多模态先验原型检索支路 (Prototype Retrieval Stream)

视觉 + 文本质心
$[\tilde{X}^{\text{image}}; \tilde{X}^{\text{text}}]$

PrototypeRetriever
余弦相似度软注意力打分
计算各基元波形匹配权重

Prototype Bank (先验原型库：周期基 + 趋势基)
低频正弦 | 高频余弦 | 上升趋势 | 复合包络

先验原型 $\tilde{\mathcal{P}} \in \mathbb{R}^{N_p \times D}$

解码下路 · 未来多模态条件解码支路 (ConditionDecoder Stream)

编码融合表征
$X^{\text{fuse}} \in \mathbb{R}^{N \times D}$
构造未来查询初值

Causal-Transformer
Mask MSA 因果自注意力 | Add&Norm + FFN | ×L 层 时序递推

Cross-Transformer (含 RoPE)
RoPE + MCA 跨模态上下文对齐 | Add&Norm + FFN | ×L 层 交叉解码

未来引导条件
1 2 n
$X^{\text{cond}} \in \mathbb{R}^{N_p \times D}$

原型引导流匹配生成 (Prototype-Guided Flow Matching)

Time & Noise
$\tau, \epsilon \sim \mathcal{N}(0, I)$

先验原型 $\tilde{\mathcal{P}}$

引导条件 X^{cond}

Flow-Matching Net (AdaLN)
预测最优传输速度场

v_θ

欧拉 ODE 积分演化
$\tau = 0$
$\tau = 1 \Longrightarrow \hat{Y}$

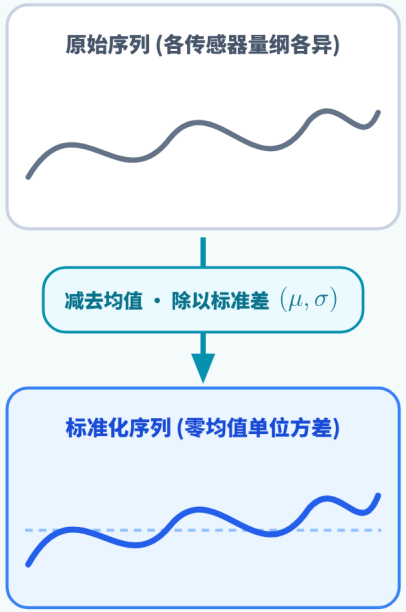
RevIN 逆归一化还原量纲

一维时间序列分块与动态重采样嵌入

通过可逆实例归一化消除多变量量纲差异，利用首部左补零分块与嵌入核线性插值重采样，将任意采样周期的一维序列映射为局部时序特征。

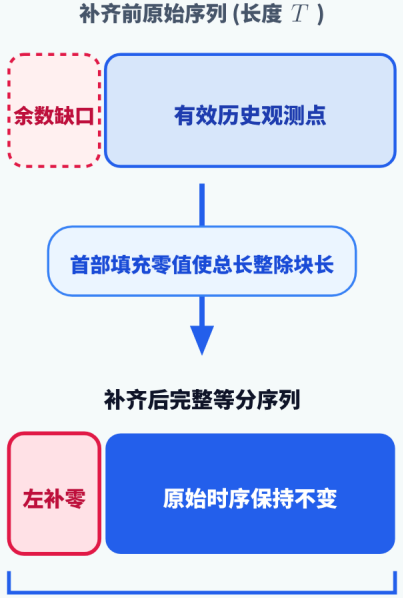
PHASE 01 统计解耦与边界对齐

STEP 01 可逆实例归一化 · 统计校准



逐通道减去历史均值 μ 并除以标准差 σ，消除非平稳偏移与物理量纲差异；统计量缓存用于预测末端逆还原。

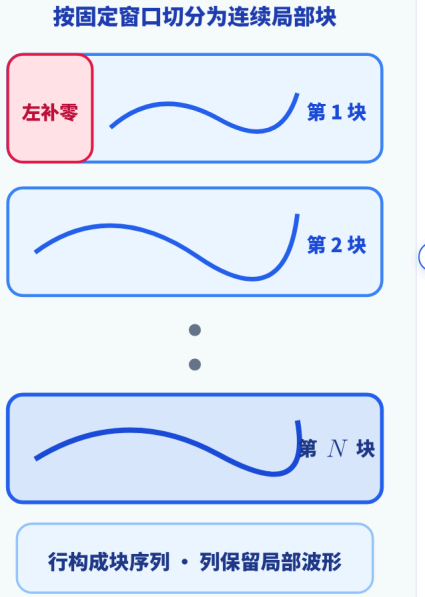
STEP 02 序列首部左补零对齐 · 边界对齐



当序列长度 T 无法被分块长度 P 整除时，在序列最左侧填充 r 个零值，保证最新历史时刻完整落在末尾分块中。

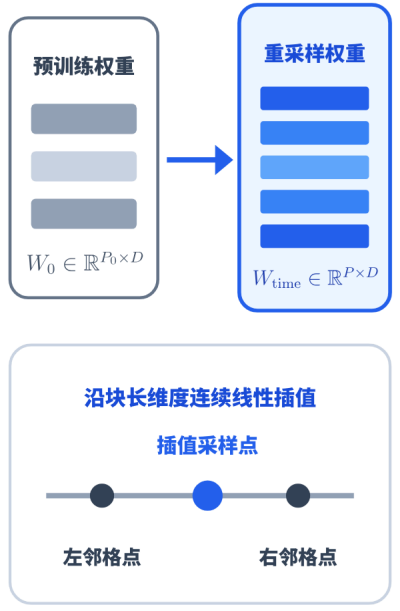
PHASE 02 局部窗口化与动态核重采样

STEP 03 非重叠等长窗口分块 · 局部窗口化



将补齐后的序列按固定块长 P 切分为 N 个连续局部时间块，每一行代表一个局部时间窗口内的短时波形形态。

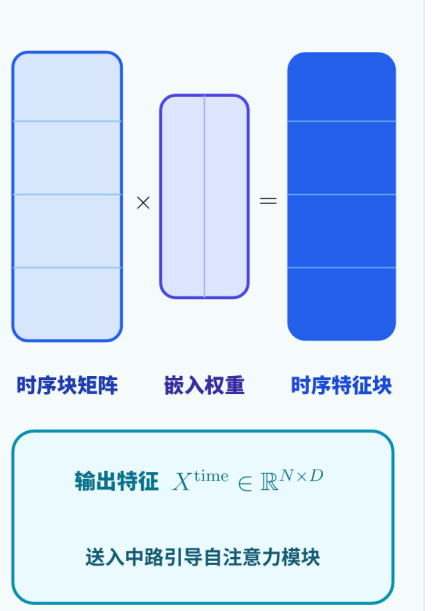
STEP 04 嵌入权重线性插值 · 核心算子



沿块长维度对预训练嵌入矩阵 W_0 执行线性插值重采样，使模型无需重新训练即可适配不同采样率与窗口长度 P。

PHASE 03 隐空间表征映射

STEP 05 线性映射生成时序特征 · 特征输出



将切分好的时序块矩阵 X_p 与重采样后的嵌入权重 W_{time} 相乘，投影至 D 维隐空间生成初始时序特征 X^{time}。

---

01 零均值单位方差标准化

$$\mu = \text{Mean}(x_{1:T}),\ \sigma = \text{Std}(x_{1:T})$$
$$\tilde{x}_t = (x_t - \mu)/(\sigma + \epsilon)$$

$\mathbb{R}^T \to \mathbb{R}^T$

02 首部余数补零扩展

$$r = (P - (T \bmod P)) \bmod P$$
$$\tilde{x}_{\text{pad}} = [\mathbf{0}_r,\ \tilde{x}_{1:T}]$$

$\mathbb{R}^T \to \mathbb{R}^{NP}$

03 一维序列重塑为块矩阵

$$N = (T + r)/P$$
$$X_p = \text{Reshape}(\tilde{x}_{\text{pad}},\ N,\ P)$$

$\mathbb{R}^{NP} \to \mathbb{R}^{N \times P}$

04 嵌入核动态线性插值

$$\alpha(p) = (p/P) \cdot P_0$$
$$W_{\text{time}} = \text{Interp}_{1\text{D}}(W_0,\ P_0 \to P)$$

$\mathbb{R}^{P_0 \times D} \to \mathbb{R}^{P \times D}$

05 矩阵乘法特征投影

$$X_p \in \mathbb{R}^{N \times P},\ W_{\text{time}} \in \mathbb{R}^{P \times D}$$
$$X^{\text{time}} = X_p\, W_{\text{time}}$$

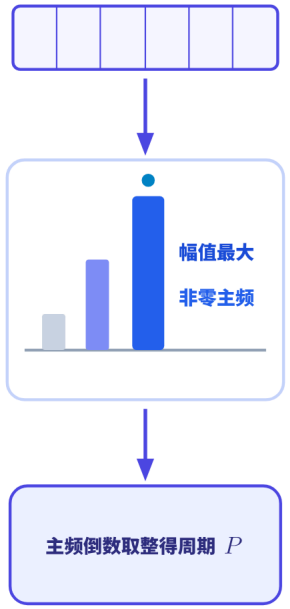
$\mathbb{R}^{N \times P} \to \mathbb{R}^{N \times D}$

二维内生周期图像构建与视觉编码

利用快速傅里叶变换自动识别序列主导周期并按周期折叠为二维矩阵，经双线性插值与三通道扩展后输入预训练视觉编码器提取跨周期纹理特征。

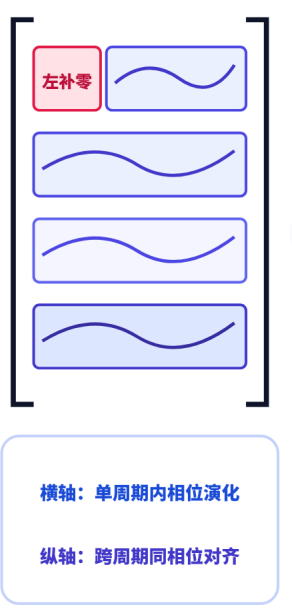
PHASE 01 频域识周期与二维折叠

STEP 01 频域提取主导周期



去除直流分量后经 FFT 提取幅值最大的非零主频 f^*，取整得到主导周期长度 P。

STEP 02 二维周期矩阵折叠



左补零后按周期长度 P 逐行折回为 K_p 行矩阵，使不同周期的同相位点在纵轴对齐。

PHASE 02 视觉标准接口适配

STEP 03 双线性插值放缩



通过二维双线性插值将任意尺寸的周期网格 G 统一缩放为 $H \times W$ 标准正方形网格。

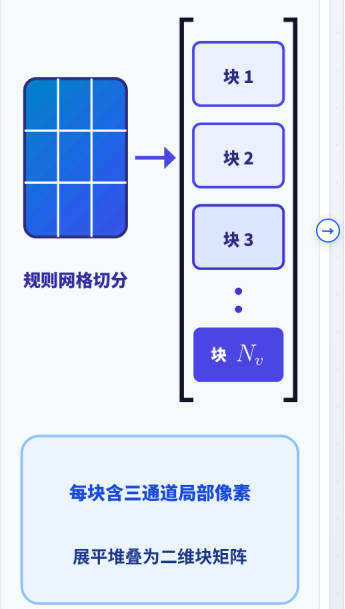
STEP 04 三通道复制扩展



将单通道周期灰度矩阵 I_1 沿通道维复制 3 份，构造三通道图像 I_3 以对接预训练视觉模型。

PHASE 03 分块嵌入与 ViT 纹理编码

STEP 05 二维网格切块展平



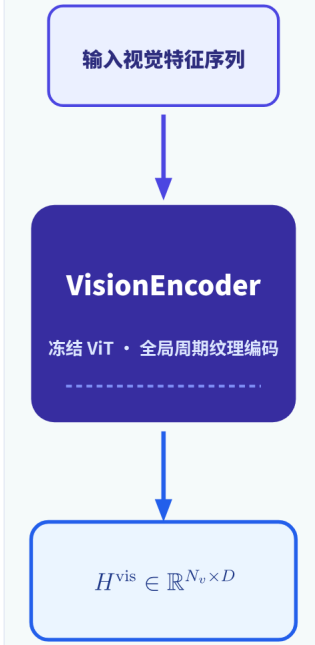
按 $S \times S$ 像素网格切分为 N_v 个局部图像块，并将每个二维块展平为特征向量。

STEP 06 线性投影与位置编码



通过线性层映射至 D 维并叠加二维可学习空间位置编码 $E_{\text{pos}}^{\text{2D}}$，保留相位坐标感知。

STEP 07 冻结 ViT 视觉编码



输入冻结参数的预训练 Vision Transformer，提取全局跨周期演进纹理特征 H^{vis}。

---

01 频谱峰值识周期

$$f^* = \arg\max |\text{FFT}(\tilde{x})|$$
$$P = \lfloor T/f^* \rfloor$$

$\mathbb{R}^T \to P \in \mathbb{Z}^+$

02 按周期换行重排

$$K_p = \lceil T/P \rceil$$
$$G = \text{Fold}_{\text{2D}}(\tilde{x}_{\text{pad}}, K_p, P)$$

$\mathbb{R}^{K_p P} \to \mathbb{R}^{K_p \times P}$

03 二维双线性插值

$$G \in \mathbb{R}^{K_p \times P}$$
$$I_1 = \text{Resize}(G, H, W)$$

$\mathbb{R}^{K_p \times P} \to \mathbb{R}^{H \times W}$

04 通道维复制叠加

$$I_1 \in \mathbb{R}^{H \times W \times 1}$$
$$I_3 = \text{Repeat}(I_1,\ 3)$$

$\mathbb{R}^{H \times W} \to \mathbb{R}^{H \times W \times 3}$

05 网格分块与展平

$$N_v = (H/S) \cdot (W/S)$$
$$U_v = \text{Patch}(I_3,\ S^2)$$

$\mathbb{R}^{H \times W \times 3} \to \mathbb{R}^{N_v \times 3S^2}$

06 投影与空间坐标注入

$$U_v W_v \in \mathbb{R}^{N_v \times D}$$
$$Z_v^{(0)} = U_v W_v + E_{\text{pos}}^{\text{2D}}$$

$\mathbb{R}^{N_v \times 3S^2} \to \mathbb{R}^{N_v \times D}$

07 预训练视觉主干编码

$$Z_v^{(0)} \in \mathbb{R}^{N_v \times D}$$
$$H^{\text{vis}} = \text{ViT}(Z_v^{(0)})$$

$\mathbb{R}^{N_v \times D} \to \mathbb{R}^{N_v \times D}$

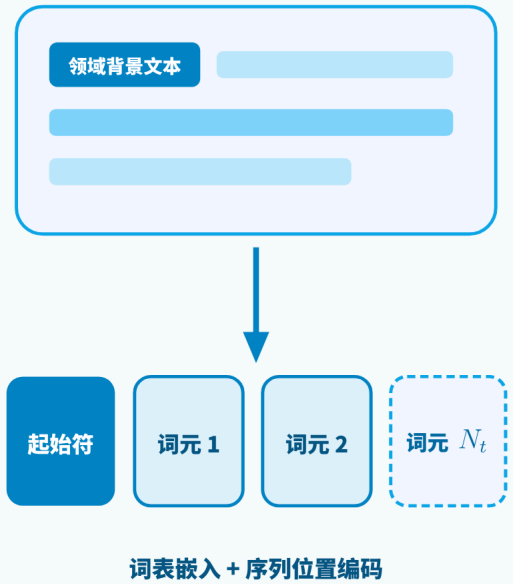
多模态特征提取与质心自适应蒸馏

基于冻结的预训练语言与视觉模型提取初始语义和周期特征，通过可学习质心交叉注意力过滤冗余背景噪声，浓缩固定数量的领域核心特征。

PHASE 01 双路冻结预训练主干编码

STEP 01 领域文本分词与位置嵌入

文本嵌入



词表嵌入 + 序列位置编码

将传感器物理属性、节假日或气象事件描述切分为 N_t 个子词词元，映射为词向量并叠加序列位置编码 $E^{\text{text}}_{\text{pos}}$。

STEP 02 双路冻结预训练主干编码

冻结主干

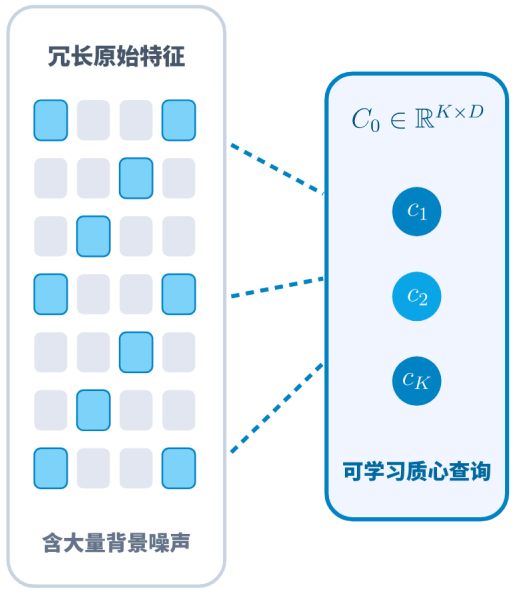


上路通过冻结的 BERT 提取上下文语义特征 H^{text}，下路通过冻结的 ViT 提取二维周期纹理特征 H^{vis}。

PHASE 02 可学习质心交叉注意力漏斗提纯

STEP 03 可学习质心交叉注意力聚合

核心算子



引入 K 个可学习质心向量 C_0 作为 Query，以原始长序列 H 作为 Key 与 Value 计算交叉注意力，自动吸附关键趋势与周期特征。

STEP 04 漏斗提纯输出紧凑先验质心

瓶颈提纯



经残差连接与前馈网络输出高度浓缩的 K 个文本质心 $\tilde{X}^{\text{text}}$ 与 K 个视觉质心 $\tilde{X}^{\text{image}}$，大幅降低后续跨模态交互开销。

01 子词切分与词向量嵌入

$$U_t = \text{Tokenizer}(\text{Text})$$
$$Z_t^{(0)} = U_t W_e + E^{\text{text}}_{\text{pos}}$$

$\text{Text} \to \mathbb{R}^{N_t \times D}$

02 冻结预训练主干前向提取

$$H^{\text{text}} = \text{BERT}(Z_t^{(0)})$$
$$H^{\text{vis}} = \text{ViT}(Z_v^{(0)})$$

$\mathbb{R}^{N_t \times D},\ \mathbb{R}^{N_v \times D}$

03 质心查询交叉注意力打分

$$Q_c = C_0 W_Q, \quad K_m = H^m W_K$$
$$A^m_{\text{dist}} = \text{Softmax}(Q_c K_m^\top / \sqrt{d_k})$$

$\mathbb{R}^{K \times N_{\text{raw}}}\ (K \ll N_{\text{raw}})$

04 瓶颈压缩输出精炼先验

$$\tilde{X}^{\text{text}} = \text{Distill}(C_0,\ H^{\text{text}})$$
$$\tilde{X}^{\text{image}} = \text{Distill}(C_0,\ H^{\text{vis}})$$

$\mathbb{R}^{N_{\text{raw}} \times D} \to \mathbb{R}^{K \times D}$

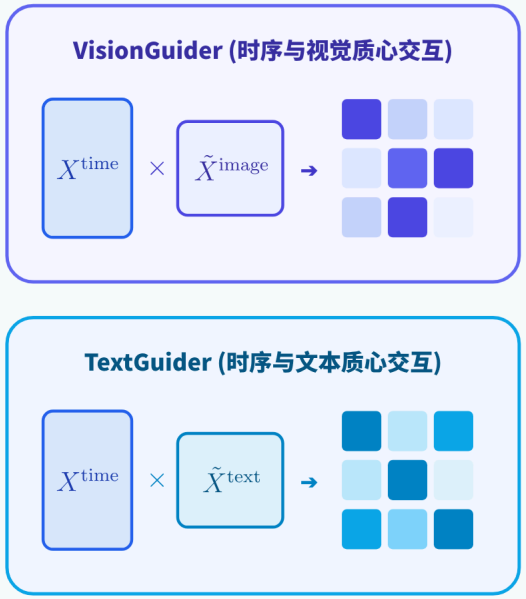
双路引导多头自注意力与跨模态融合

利用文本与视觉引导器计算跨模态双线性相关性矩阵以调制一维时序自注意力权重，并通过跨模态交叉注意力与残差连接输出三路融合表征。

PHASE 01 双路跨模态相关性先验构建

STEP 01 双路引导器跨模态关联打分

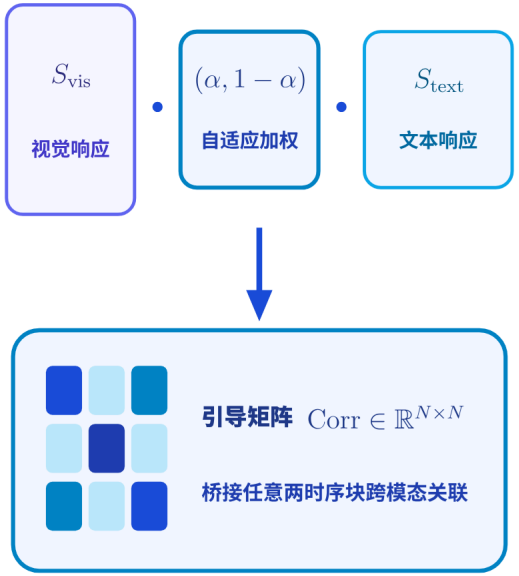
双线性打分



TextGuider 与 VisionGuider 分别通过可学习双线性映射矩阵 W_{text}、W_{vis} 计算每个一维时序块与文本、视觉质心的关联响应。

STEP 02 合成时间块相关性引导矩阵

引导矩阵合成

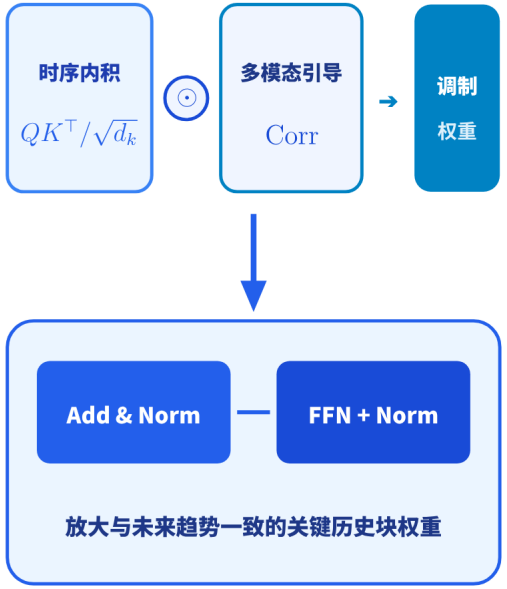


若两个时间块对同一文本事件或同一周期相位质心均有高响应，则在相关性矩阵 Corr 中赋予高权重，显式建立跨时间步先验连接。

PHASE 02 相关性调制自注意力与三路残差汇聚

STEP 03 相关性调制多头自注意力

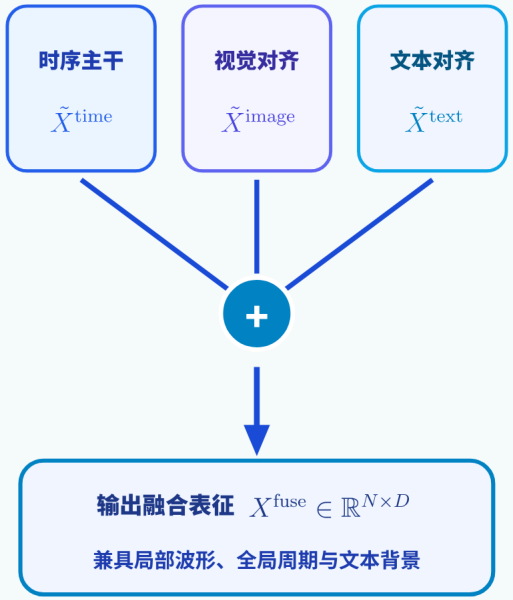
核心算子



将多模态相关矩阵 Corr 与中路标准点积注意力分数逐元素哈达玛积（$\odot$）调制，经 K 层堆叠演化输出引导后时序特征 $\tilde{X}^{\text{time}}$。

STEP 04 三路跨模态交叉注意力汇聚

三路汇聚



在 Modality Fuser 中以 $\tilde{X}^{\text{time}}$ 为 Query，分别与文本质心 $\tilde{X}^{\text{text}}$、视觉质心 $\tilde{X}^{\text{image}}$ 执行交叉注意力对齐并残差相加，输出 X^{fuse}。

01 双线性跨模态关联度计算

$$S_{\text{text}} = \sigma\left(X^{\text{time}} W_{\text{text}} (\tilde{X}^{\text{text}})^{\top}\right)$$
$$S_{\text{vis}} = \sigma\left(X^{\text{time}} W_{\text{vis}} (\tilde{X}^{\text{image}})^{\top}\right)$$

$\mathbb{R}^{N\times D} \to \mathbb{R}^{N\times K}$

02 双路相关性矩阵加权合成

$$C_m = \text{Softmax}(S_m S_m^{\top})$$
$$\text{Corr} = \alpha\, C_{\text{text}} + (1-\alpha)\, C_{\text{vis}}$$

$\mathbb{R}^{N\times K} \to \mathbb{R}^{N\times N}$

03 相关性调制多头自注意力

$$A_{\text{MG}} = \text{Softmax}\left((QK^{\top}/\sqrt{d_k}) \odot \text{Corr}\right)$$
$$\tilde{X}^{\text{time}} = \text{FFN}\left(\text{LN}(X^{\text{time}} + A_{\text{MG}} V)\right)$$

$\mathbb{R}^{N\times D} \to \mathbb{R}^{N\times D}$

04 三路交叉注意力残差融合

$$F_{\text{mm}} = \text{MCA}(\tilde{X}^{\text{time}}, \tilde{X}^{\text{text}}) + \text{MCA}(\tilde{X}^{\text{time}}, \tilde{X}^{\text{image}})$$
$$X^{\text{fuse}} = \text{LN}(\tilde{X}^{\text{time}} + F_{\text{mm}})$$

$\mathbb{R}^{N\times D} \to \mathbb{R}^{N\times D}$

先验原型检索、条件解码与流匹配生成

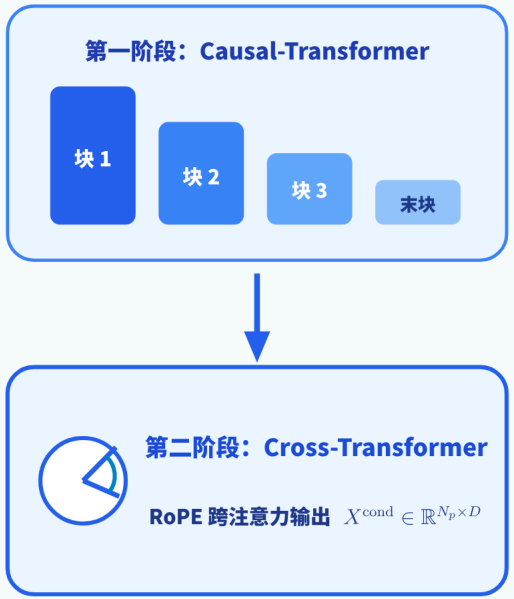
结合因果与旋转位置编码跨注意力解码未来步控制条件，同时从多尺度周期与趋势原型库中检索初始波形锚点，经条件流匹配常微分方程积分生成最终预测。

PHASE 01 双路解码先验准备 (条件 X^cond + 原型 P̃)

PHASE 02 原型锚定最优传输流匹配生成

STEP 01 因果与旋转位置编码条件解码

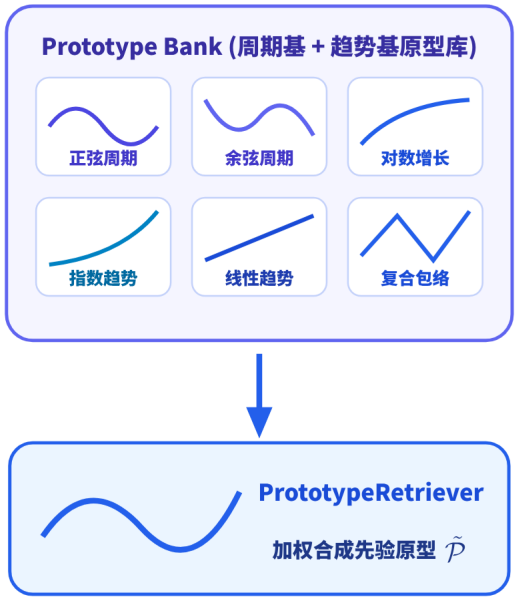
未来条件解码



将编码融合表征 X^{fuse} 送入带下三角掩码的 Causal-Transformer 与引入旋转位置编码（RoPE）的 Cross-Transformer，外推得到未来 N_p 个分块的控制条件 X^{cond} 。

STEP 02 多尺度先验原型库软检索

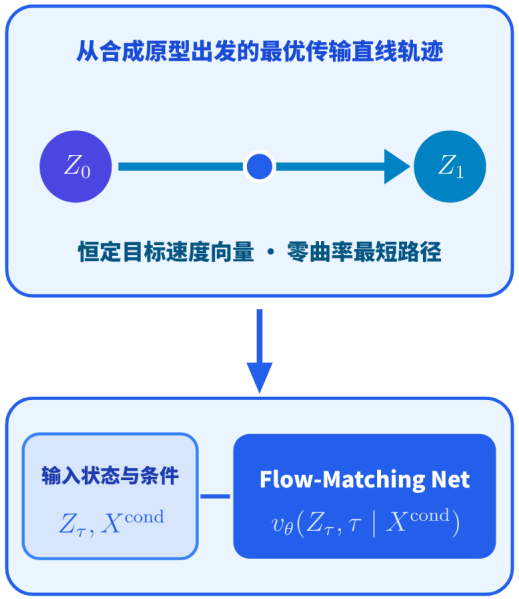
先验起点检索



以蒸馏后的视觉与文本质心构造查询向量 Q_{mm}，与可学习原型库 B_{bank}（涵盖正弦周期基与多项式趋势基）计算相似度，加权合成初始先验原型 $\tilde{\mathcal{P}}$。

STEP 03 原型锚定条件流匹配速度场学习

核心算子



以叠加高斯微扰 ϵ 的先验原型 $Z_0 = \tilde{\mathcal{P}} + \sigma_0 \epsilon$ 为流起点，在流时间步 $\tau \in [0,1]$ 上通过 AdaLN 注入条件 X^{cond}，训练网络预测指向真实分布 Z_1 的直线速度向量 v_θ。

STEP 04 前向欧拉积分与逆归一化还原

终端生成还原



推理时从 $\tau = 0$ 的先验起点 Z_0 出发，沿预测速度场 v_θ 执行常微分方程（ODE）欧拉数值积分到达 $\tau = 1$，经线性投影与 RevIN 逆归一化输出最终预测分布 $\hat{Y}$。

01 因果掩码与 RoPE 跨注意力解码

$$H_{\text{causal}} = \text{CausalAttn}(X^{\text{fuse}})$$
$$X^{\text{cond}} = \text{RoPE-Attn}\big(H_{\text{causal}},\ [\tilde{X}^{\text{image}}; \tilde{X}^{\text{text}}]\big)$$

$\mathbb{R}^{N \times D} \to \mathbb{R}^{N_p \times D}$

02 多尺度周期与趋势原型检索

$$\alpha_{\text{proto}} = \text{Softmax}(Q_{\text{mm}} B_{\text{bank}}^{\top} / \sqrt{D})$$
$$\tilde{\mathcal{P}} = \alpha_{\text{proto}}\, B_{\text{bank}}$$

$B_{\text{bank}} \in \mathbb{R}^{M_b \times D} \to \tilde{\mathcal{P}} \in \mathbb{R}^{N_p \times D}$

03 最优传输直线速度场回归

$$Z_\tau = (1-\tau)(\tilde{\mathcal{P}} + \sigma_0 \epsilon) + \tau Z_1$$
$$\mathcal{L}_{\text{FM}} = \mathbb{E}\big\| v_\theta(Z_\tau, \tau \mid X^{\text{cond}}) - (Z_1 - Z_0) \big\|_2^2$$

$v_\theta \in \mathbb{R}^{N_p \times D}$

04 多步欧拉积分与物理量纲还原

$$Z_{\tau+\Delta\tau} = Z_\tau + \Delta\tau\, v_\theta(Z_\tau, \tau \mid X^{\text{cond}})$$
$$\hat{Y} = \text{RevIN}^{-1}(Z_1 W_{\text{out}})$$

$\mathbb{R}^{N_p \times D} \to \hat{Y} \in \mathbb{R}^{H_f}$