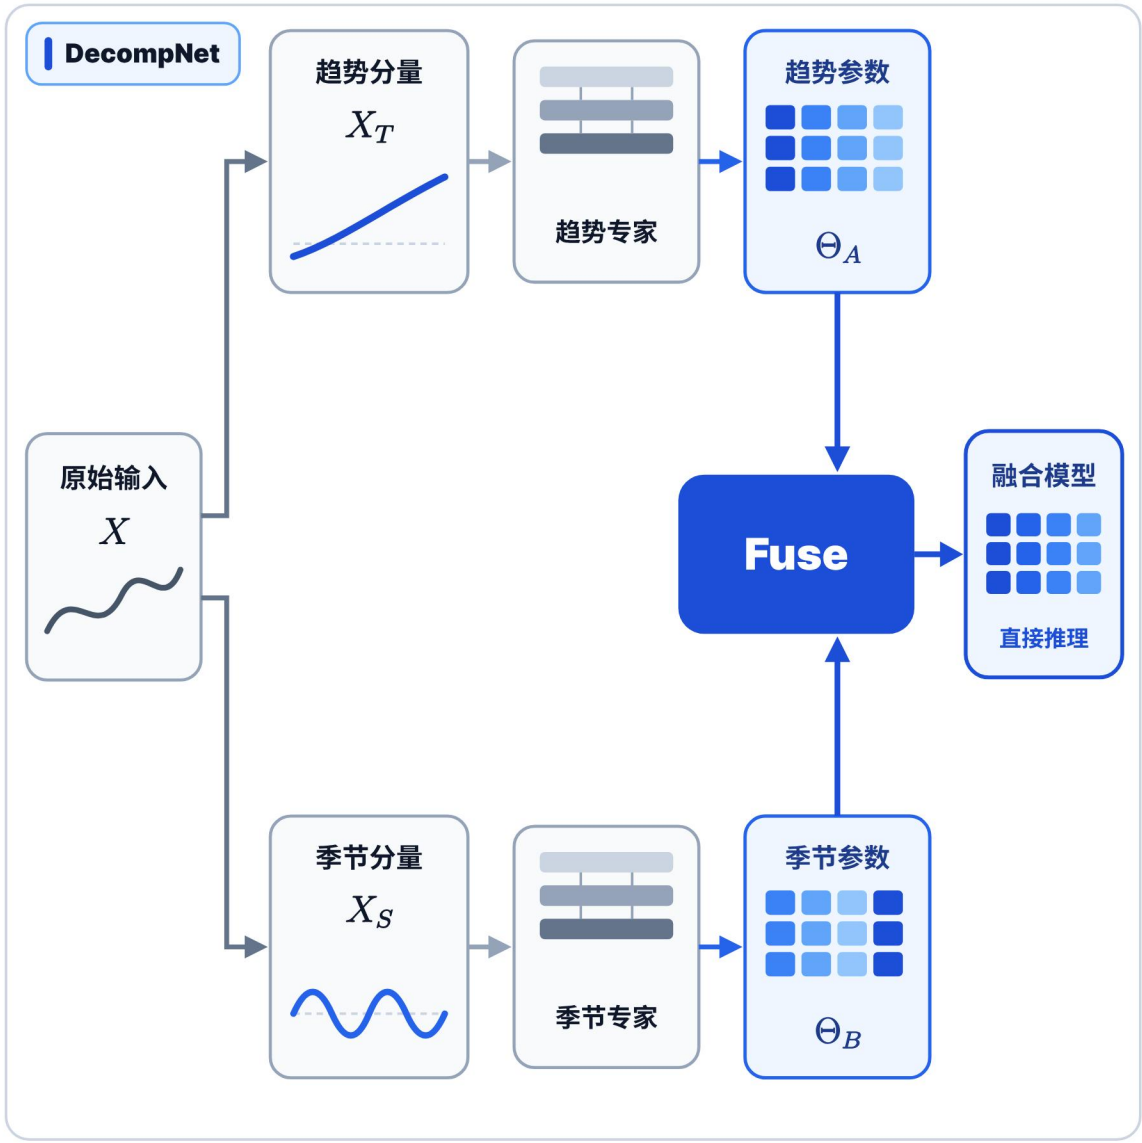
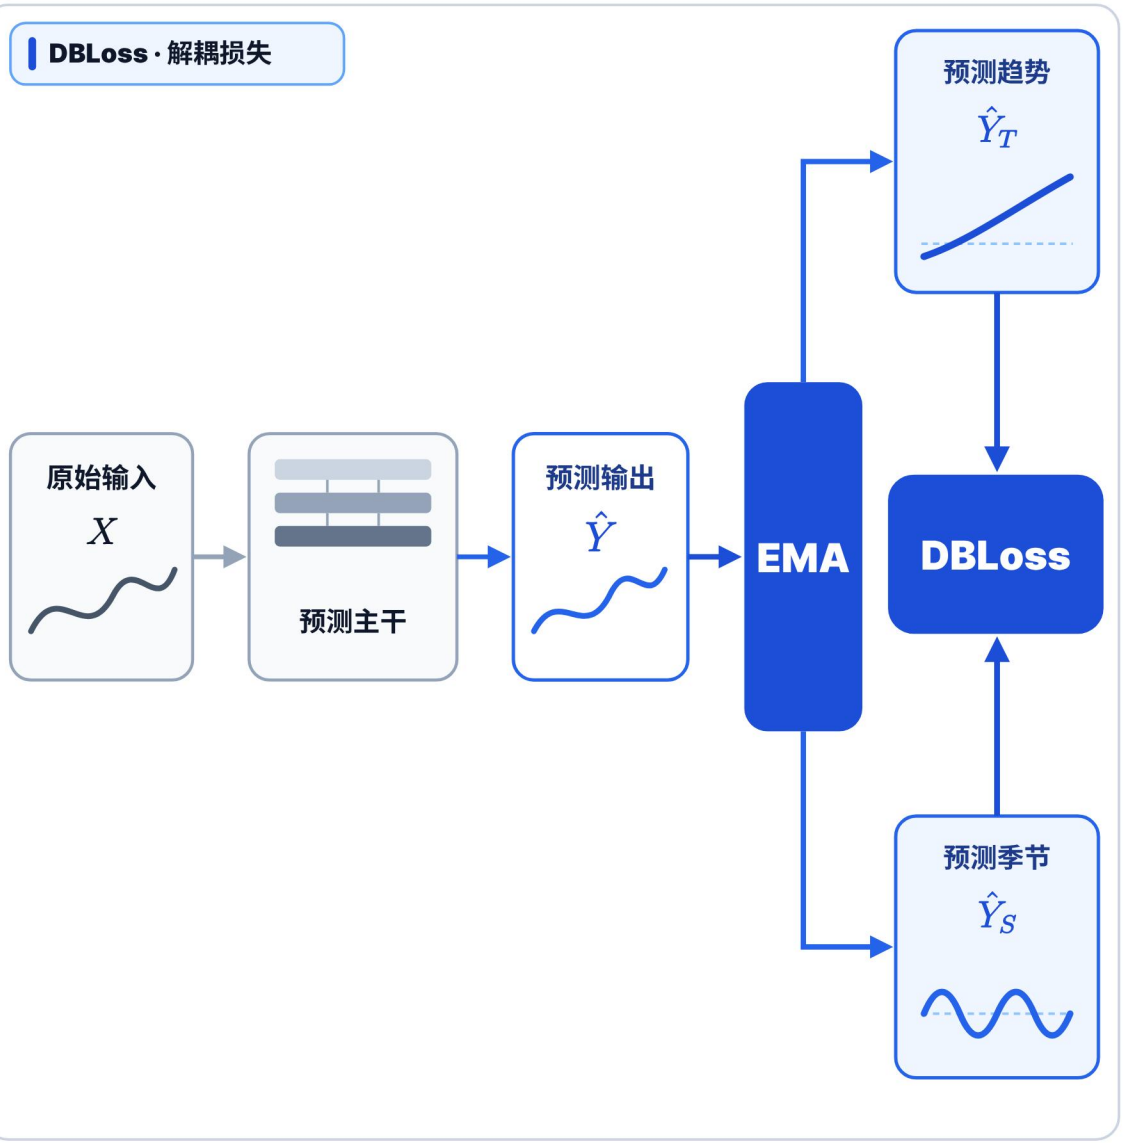
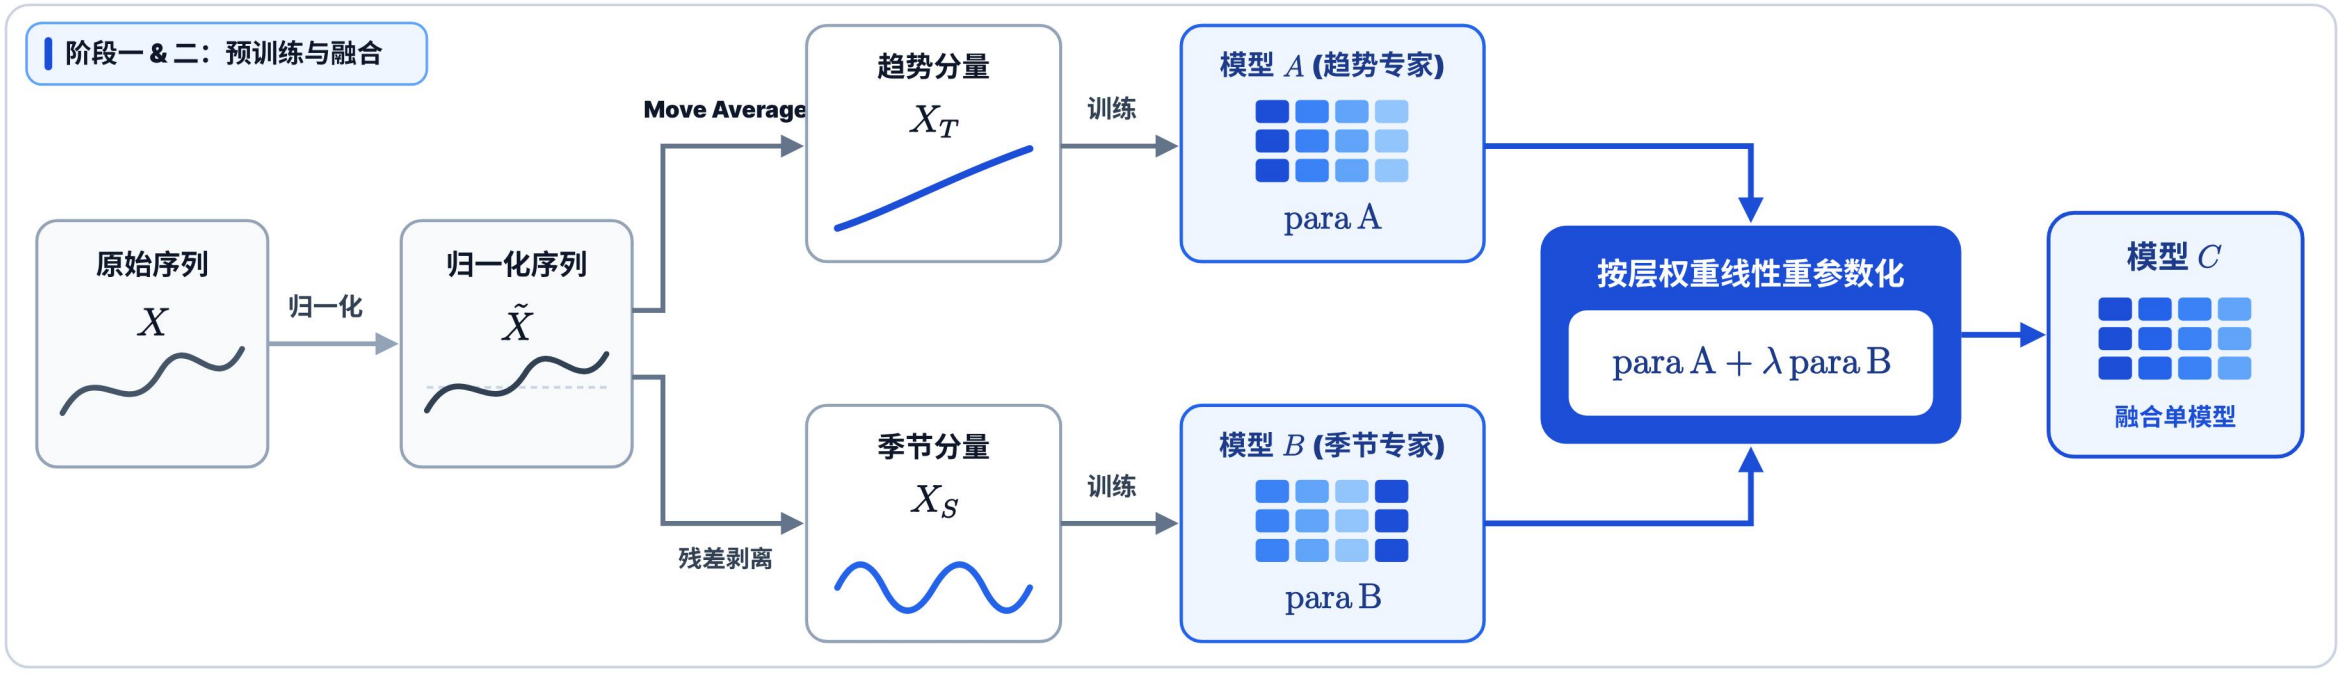
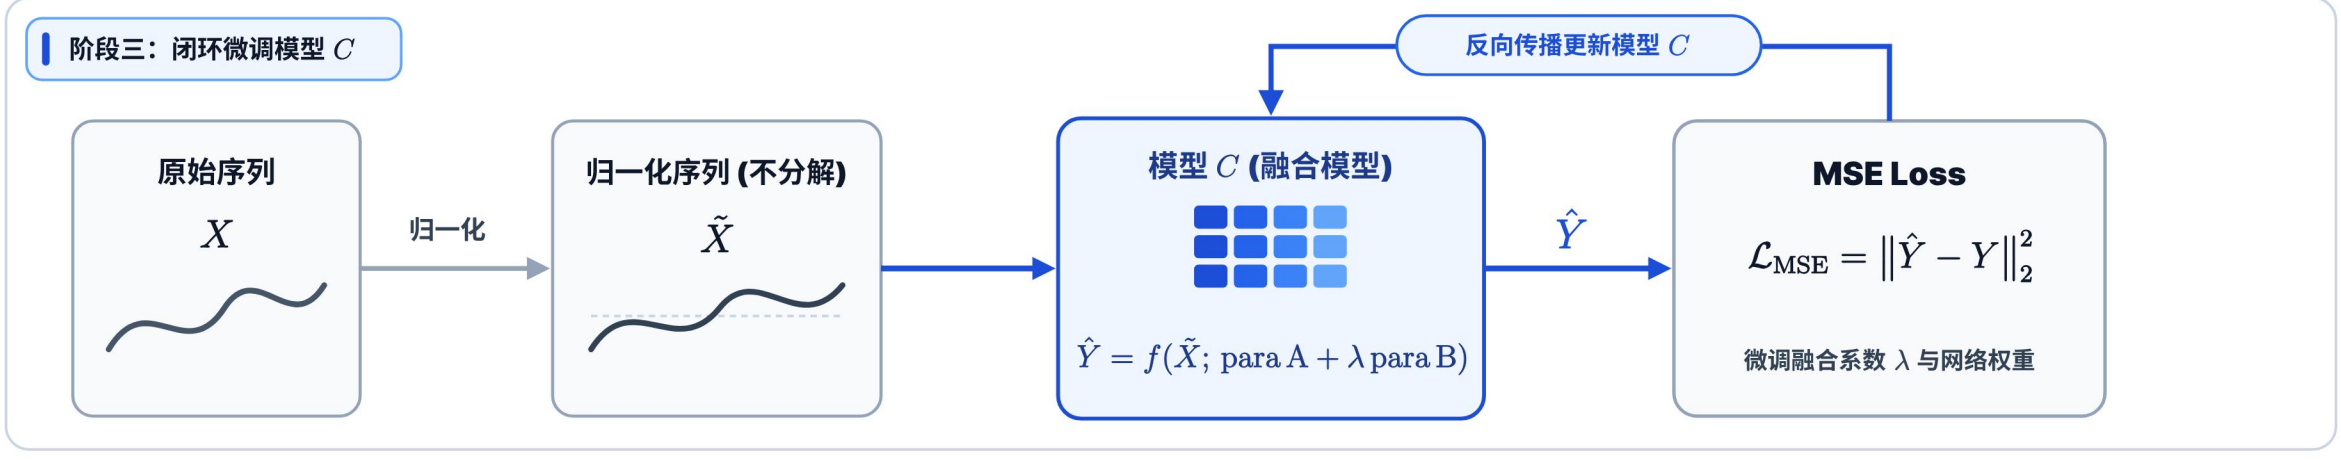
分解趋势与季节性：DecompNet 与 DBLoss





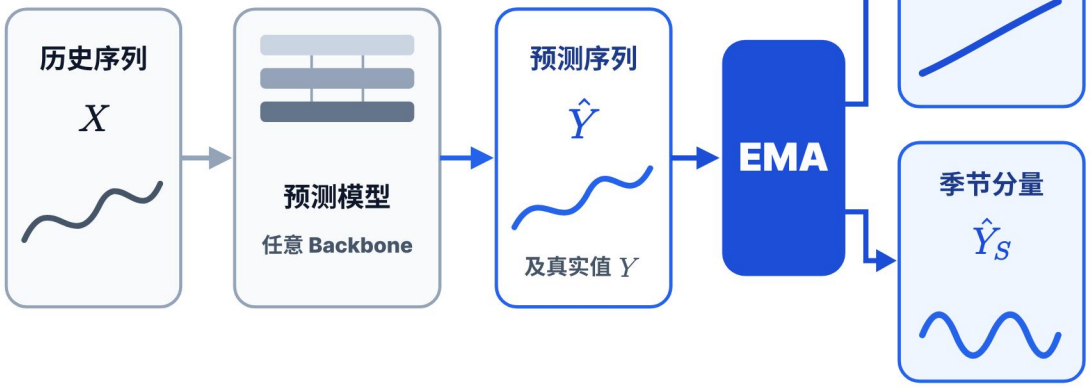
DecompNet：解耦训练与参数融合（无法复现）





DBLoss：输出端 EMA 分解与尺度对齐损失（提升显著）

指数衰减滑动平均 (Exponential Moving Average, EMA)



2. 损失与对齐

α, β 为超参数

季节 (L_2) $\mathcal{L}_S = \|\hat{Y}_S - Y_S\|_2$

趋势 (L_1) $\mathcal{L}_T = \|\hat{Y}_T - Y_T\|_1$

无梯度尺度对齐

stopgrad 截断梯度

$$\mathcal{L}_T^{\text{aligned}} := \mathcal{L}_T \times \text{stopgrad}\left(\frac{\mathcal{L}_S}{\mathcal{L}_T + \epsilon}\right)$$

DBLoss 总损失

$$\mathcal{L} := \beta \cdot \mathcal{L}_S + (1 - \beta) \cdot \mathcal{L}_T^{\text{aligned}}$$

3. EMA 算子

$$\text{Trend} = A\,\hat{Y}$$

$$\text{Seasonality} = (I - A)\,\hat{Y}$$

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 \\ q & \alpha & 0 & 0 \\ q^2 & \alpha q & \alpha & 0 \\ q^3 & \alpha q^2 & \alpha q & \alpha \end{bmatrix}, \qquad q = 1 - \alpha$$

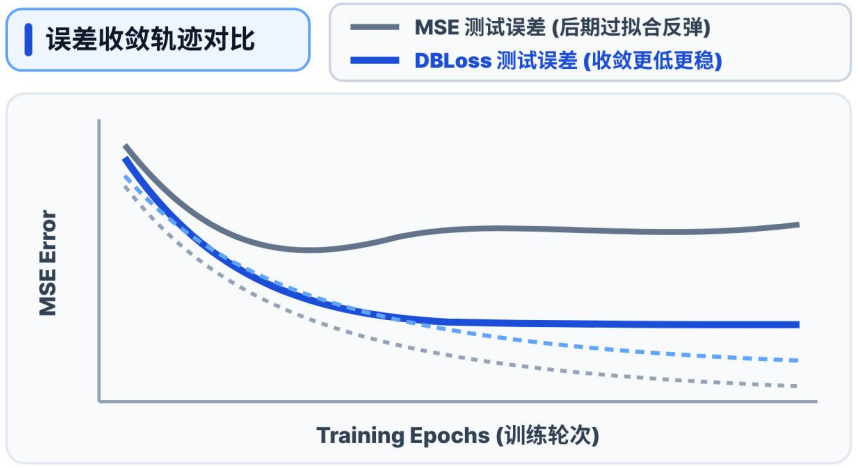
DBLoss 实验结果与本地复现对比（运行中）

主流主干 MSE vs DBLoss (MSE / MAE)

状态：本地复现运行中

数据集	预测主干	Original (MSE)	DBLoss (论文)	DBLoss (复现)	相对变化
ETTh1	iTransformer	0.439 / 0.448	0.423 / 0.430	Running · 待填入	-3.6%
ETTh1	PatchTST	0.419 / 0.436	0.402 / 0.420	Running · 待填入	-4.1%
ETTh1	DLinear	0.425 / 0.439	0.412 / 0.425	Running · 待填入	-3.1%
ETTh2	PatchTST	0.351 / 0.395	0.337 / 0.381	Running · 待填入	-4.0%
ETTh2	DLinear	0.470 / 0.468	0.409 / 0.424	Running · 待填入	-13.0%
ETTm1	iTransformer	0.361 / 0.390	0.350 / 0.376	Running · 待填入	-3.0%
ETTm2	iTransformer	0.269 / 0.327	0.262 / 0.317	Running · 待填入	-2.6%
Weather	DLinear	0.242 / 0.293	0.239 / 0.280	Running · 待填入	-4.4%
Traffic	PatchTST	0.397 / 0.275	0.395 / 0.267	Running · 待填入	-2.9%

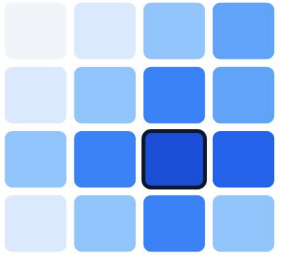
误差收敛轨迹对比



分解损失起到隐式正则化作用，抑制对训练集高频噪声的过拟合

超参数 (α, β) 敏感度

(α, β) 误差分布网格



横轴：权重 β · 纵轴：系数 α

深蓝格：最优 (α^*, β^*)

1. 强周期数据 (Traffic)

宜取较大 β (强化周期) 与小 α

本地最优：[待实验填入]

2. 强趋势数据 (ETTh2)

宜取均衡 $\beta \in [0.4, 0.5]$ 兼顾双项

本地最优：[待实验填入]

3. 复现差异核对重点

对比默认超参 vs 逐数据集搜索

核查长步长 EMA 浮点稳定性

复现反思：DecompNet 与 DBLoss 机制对比与差异剖析

01 DecompNet 失效剖析

参数硬融合

未分解输入 $X_T + X_S$ × 融合层权重 $W_A + \lambda W_B$ → 正常专家项 / 交叉污染项

趋势流形 Θ_A — 非线性失配 $\Theta_A + \lambda\Theta_B$ — 季节流形 Θ_B

$$f(X_T;\Theta_A) + f(X_S;\Theta_B) \neq f(\tilde{X};\Theta_A + \lambda\Theta_B)$$

未分解输入激活跨分量交叉污染项

$$(X_T + X_S)(W_A + \lambda W_B) = (X_T W_A + \lambda X_S W_B) + (\lambda X_T W_B + X_S W_A)$$

非线性激活与注意力破坏参数可加性

Softmax、LayerNorm 与激活函数均为强非线性，
按层权重线性相加会偏离各自收敛的特征子空间。

三阶段微调链路脆弱，实测无法复现

微调单标量 λ 远不足以消除深层交叉干扰，复现失败。

02 DBLoss 稳定有效机制

输出线性正交

传统 MSE：趋势残差与季节梯度相互耦合干扰

趋势残差 $T - \hat{T}$ ⟷ 耦合互扰 ⟷ 季节雅可比 $\mathbf{J}_S = \nabla_\Theta \hat{S}$

DBLoss：线性矩阵算子正交拆解 · 双路独立回传梯度

趋势算子 $A\hat{Y}$ → 经 $A^\top$ 回传纯趋势 L_1 梯度

季节算子 $(I - A)\hat{Y}$ → 经 $(I - A)^\top$ 回传纯季节 L_2 梯度

从根源消除 MSE 的趋势-季节交叉耦合梯度

$$\mathbf{G}_{\text{coupling}} = -2\left[(T - \hat{T})\mathbf{J}_S + (S - \hat{S})\mathbf{J}_T\right] \neq \mathbf{0}$$

线性矩阵算子可微且无损，梯度回传干净

A 与 $I - A$ 均为固定线性变换，反向传播通过矩阵转置
将 L_1 趋势与 L_2 季节监督精确回传至输出端，无流形失配。

stopgrad 尺度对齐兼顾双分量，即插即用

无需修改模型结构，在多主干与数据集上均稳健提升。

03 复现差异与超参匹配

矩阵化与调参

论文伪代码 (Algorithm 1)：前缀和除以衰减项 (易下溢)

$$\text{Trend}_t = \frac{\text{cumsum}(\hat{Y} \odot W)_t}{D_{\text{div},t}}, \quad D_{\text{div},t} = q^{F-1-t}$$

矩阵化实现：下三角矩阵 A 直接相乘 (避免除法 · 全步长稳定)

$$A_{t,0} = q^t, \quad A_{t,k} = \alpha q^{t-k} \implies \text{Trend} = A\hat{Y}$$

强周期数据 (Traffic)
偏好大 β 与小 α

强趋势数据 (ETTh2)
偏好均衡 $\beta \in [0.4, 0.5]$

长预测步长下前缀和除法的浮点下溢隐患

步长 $F = 720$ 时因子 q^{719} 在 FP32 下易下溢为 0；
直接采用下三角矩阵乘法 $A\hat{Y}$ 可彻底消除小量除法误差。

超参数 (α, β) 跨数据集敏感性导致指标差异

原论文针对不同数据集与步长单独搜索了 (α, β)；固定
单一超参时虽优于 MSE，但与论文最优汇报值存在差异。

后续优化：自相关先验驱动自适应 α

结合序列主导周期自动设定 α，免去逐数据集网格搜索。